Implementação do Support Vector Machine

Implementação e explicação de códigos de SVM utilizando o repositório em python scikit-learn. Com efeito serão abordados códigos exemplos do scikit-learn modificados pelo autor voltados para utilização do Support Vector Machine utilizando o kernel RBF (Radius Base Function).

In [ ]:
```
# Importação do banco de dados a ser utilizado nos exemplos

from sklearn import datasets

iris = datasets.load_iris()

# Nesse banco de dados, os principais valores que iremos utilizar serão as entradas (iris.data) e as saídas (iris.target)

X = iris.data

Y = iris.target
```

In [ ]:
```
print("Descrição das entradas: \n", iris.feature_names)
print("Tamanho :", X.shape)
print("Entrada (apenas 5 linhas): \n", X[0:5])
```

```
Descrição das entradas:
 ['sepal length (cm)', 'sepal width (cm)', 'petal length (cm)', 'petal width (cm)']
Tamanho : (150, 4)
Entrada (apenas 5 linhas):
 [[5.1 3.5 1.4 0.2]
 [4.9 3.  1.4 0.2]
 [4.7 3.2 1.3 0.2]
 [4.6 3.1 1.5 0.2]
 [5.  3.6 1.4 0.2]]
```

In [ ]:
```
print("Descrição das saídas: \n", iris.target_names)
print("Tamanho :", Y.shape)
print("Saida: \n",Y)
```

```
Descrição das saídas:
 ['setosa' 'versicolor' 'virginica']
Tamanho : (150,)
Saida:
 [0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0
 0 0 0 0 0 0 0 0 0 0 0 0 0 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1
 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 2 2 2 2 2 2 2 2 2 2
 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2
 2 2]
```

One-class SVM with non-linear kernel (RBF) | SVM com kernel não linear (RBF) para classes unitárias de dados

Esse algoritmo é um exemplo de método não supervisionado que serve para classificar amostras como similares ou diferentes do grupo de dados de treinamento. Esse exemplo é utilizado principalmente para detectar anomalias.

In [ ]:
```
# Importação das bibliotecas a serem utilizadas:

import numpy as np
import matplotlib.pyplot as plt
import matplotlib.font_manager
from sklearn import svm
```

In [ ]:
```
# Esse algoritmo se diferencia um pouco dos outros que serão listados, uma vez que a intenção aqui é validar a coerência de um banco de dados.

# Sendo assim iremos dividir X em três conjuntos. O primeiro será para treinamento e terá 100 elementos somente de 'sepal length (cm)'.
# O segundo será para teste e terá 50 elementos de 'sepal length (cm)'. O terceiro e último será para teste de anomalias terá 50 elementos de 'sepal width (cm)'.

X_train = X[:100, 0].reshape(-1, 1) # O .reshape(-1, 1) é utilizado pois estamos trabalhando com apenas uma entrada.
X_test = X[100:150, 0].reshape(-1, 1)
X_outliers = X[:50, 1].reshape(-1, 1)
```

In [ ]:
```
# Agora iremos criar e ajustar o modelo com o conjunto de treinamento:

# Pode-se escolher entradas adicionais listadas aqui https://scikit-learn.org/stable/modules/generated/sklearn.svm.OneClassSVM.html#sklearn.svm.OneClassSVM

clf = svm.OneClassSVM(kernel="rbf", nu=0.05, gamma=0.1)
clf.fit(X_train)

# E assim, obter os modelos de predição:

Y_pred_train = clf.predict(X_train)
Y_pred_test = clf.predict(X_test)
Y_pred_outliers = clf.predict(X_outliers)

# Resultado = 1 -> Acerto | Resultado = -1 -> Erro

# Número de erros em cada modelo:
n_error_train = Y_pred_train[Y_pred_train == -1].size
n_error_test = Y_pred_test[Y_pred_test == -1].size
n_error_outliers = Y_pred_outliers[Y_pred_outliers == 1].size

print(f'Dados de treinamento: 1) Erro = {n_error_train/Y_pred_train.size} \n 2) Predição: {Y_pred_train} \n')

print(f'Dados de teste: 1) Erro = {n_error_test/Y_pred_test.size} \n 2) Predição: {Y_pred_test} \n')

print(f'Dados de anomalias: 1) Erro = {n_error_outliers/Y_pred_outliers.size} \n 2) Predição: {Y_pred_outliers} \n')
```

```
Dados de treinamento: 1) Erro = 0.03
 2) Predição: [ 1  1  1  1  1  1  1  1  1  1  1  1  1 -1  1  1  1  1  1  1  1  1  1
  1  1  1  1  1  1  1  1  1  1  1  1  1  1  1  1  1  1  1  1  1  1  1  1  1
  1  1 -1  1 -1  1  1  1  1  1  1  1  1  1  1  1  1  1  1  1  1  1  1  1  1
  1  1  1  1  1  1  1  1  1  1  1  1  1  1  1  1  1  1  1  1  1  1  1  1  1
  1  1  1  1]

Dados de teste: 1) Erro = 0.3
 2) Predição: [ 1  1 -1  1  1 -1  1 -1  1 -1  1  1  1  1  1  1  1 -1 -1  1 -1  1 -1  1
  1 -1  1  1  1 -1 -1 -1  1  1  1 -1  1  1  1 -1  1 -1  1  1  1  1  1  1
  1  1]

Dados de anomalias: 1) Erro = 0.02
 2) Predição: [-1 -1 -1 -1 -1 -1 -1 -1 -1 -1 -1 -1 -1 -1 -1 -1  1 -1 -1 -1 -1 -1 -1 -1 -1
 -1 -1 -1 -1 -1 -1 -1 -1 -1 -1 -1 -1 -1 -1 -1 -1 -1 -1 -1 -1 -1 -1 -1 -1 -1
 -1 -1]
```

In [ ]:
```
# Ademais podemos visualizar os resultados utilizando a função decisão do modelo clf:

xx, yy = np.meshgrid(np.linspace(-1, 51, 500), np.linspace(-1, 51, 500)) # Cria uam malha para plotar o mapa de calor

# Plota as linhas para a função de decisão
Z = clf.decision_function(np.c_[yy.ravel()])
Z = Z.reshape(xx.shape)

plt.title("Novelty Detection")
plt.contourf(xx, yy, Z, levels=np.linspace(Z.min(), 0, 7), cmap=plt.cm.PuBu)
a = plt.contour(xx, yy, Z, levels=[0], linewidths=2, colors="darkred")
```

```
plt.contourf(xx, yy, Z, levels=[0, Z.max()], colors="palevioletred")

s = 40
b1 = plt.scatter(range(0,50), X_train[:50], c="white", s=s, edgecolors="k")
b12 = plt.scatter(range(0,50), X_train[50:100], c="white", s=s, edgecolors="k")
b2 = plt.scatter(range(0,50), X_test, c="blueviolet", s=s, edgecolors="k")
c = plt.scatter(range(0,50), X_outliers, c="gold", s=s, edgecolors="k")
plt.axis("tight")
plt.xlim((-1, 51))
plt.ylim((0, 12))
plt.legend(
    [b1, b2, c],
    [
        "Conjunto de treino",
        "Conjunto de teste",
        "Conjuto de anomalias",
    ],
    loc="upper left",
    prop=matplotlib.font_manager.FontProperties(size=11),
)
plt.xlabel(
    "Erro de treino: %d/100 ; Erro de teste: %d/50 ; Erro de anomalias: %d/50"
    % (n_error_train, n_error_test, n_error_outliers)
)
plt.show()
```

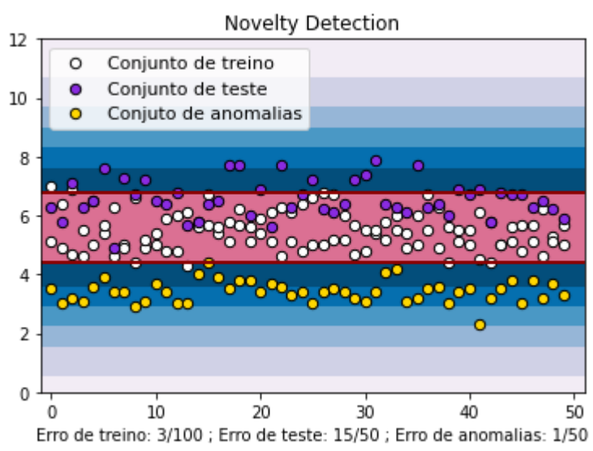

RBF SVM parameters | Parâmetros para SVM RBF

Nessa implementação iremos ver como o modelo SVM RBF varia com a variação dos parametros gamma (da função rbf) e do C (penalidade do modelo de classificação).

O parâmetro gamma define o alcance de influência de um dado de treinamento, onde pequenos valores são responsáveis por um longo alcance e grandes valores são responsáveis por um curto alcance.

O parâmetro C se comporta como uma variável de troca entre uma correta classificação de dados de treinamento e uma maximização da margem de decisão do modelo. Para valores altos de C, será obtido uma menor margem se a função decisão for boa o suficiente para classificar os dados de treinamento corretamente. Já para valores pequenos de C, resultará em uma margem maior com uma função de decisão mais simples.

Nessa implementação acharemos qual os melhores valores de gamma e C para o conjunto a ser treinado.

In [ ]:
```
# Importação das bibliotecas a serem utilizadas:

import numpy as np
import matplotlib.pyplot as plt
from sklearn.svm import SVC
from sklearn.model_selection import train_test_split
from sklearn import metrics
```

In [ ]:
```
# Para esse algoritmo, a ideia é dividir o conjunto (X e Y), dos valores importados no início, em entradas e saídas de treinamento e teste
# (X_train e X_test, Y_train e Y_test) de uma maneira a encontrar os melhores valores desse conjunto, entre 100 loops,
# que resultaram nos modelos mais exatos para os diferentes valores de C e gamma que definiremos.

modelos = []

for j in range(100):

    # Dividimos o conjunto de dados, sendo 30% para teste e 70% para treinamento:

    X_train, X_test, Y_train, Y_test = train_test_split(X, Y, test_size=0.3)

    # Iremos definar 3 valores para gamma e 3 valores para C, cruzando todos os possíveis parâmetros e montando um total de 9 classificadores diferentes:

    C_ = [1e-2, 1, 1e2]
    gamma_ = [1e-1, 1, 1e1]
    classifiers = []
    accuracy_total = 0

    # Para cada modelo, guardaremos o valor de C, gamma, clf e a accuracy

    for C in C_:
        for gamma in gamma_:
            clf = SVC(C=C, gamma=gamma)
            clf.fit(X_train, Y_train)
            Y_pred = clf.predict(X_test)
            accuracy = metrics.accuracy_score(Y_test, Y_pred)
            accuracy_total += accuracy
            classifiers.append((C, gamma, clf, accuracy))

    # Agora obtido os classifiers e a accuracy_total, iremos guardar em modelos esses valores e o conjunto dividido:

    modelos.append((classifiers, accuracy_total, [X_train, X_test, Y_train, Y_test]))

# Agora, obtidos os modelos, iremos ordenar de forma crescente tendo em vista a accuracy_total:

for i in range(len(modelos)):
    for j in range(i + 1, len(modelos)):
        if modelos[i][1] > modelos[j][1]:
            modelos[i], modelos[j] = modelos[j], modelos[i]

# Dessa forma, conseguimos achar o modelo que tem o melhor desempenho:

best_classifiers = modelos[-1][0]
best_accuracy_total = modelos[-1][1]
best_train_test = modelos[-1][2]

# Assim, iremos ordenar o modelo best para achar os melhores valores para C e gamma

for i in range(len(best_classifiers)):
    for j in range(i + 1, len(best_classifiers)):
        if best_classifiers[i][3] > best_classifiers[j][3]:
            best_classifiers[i], best_classifiers[j] = best_classifiers[j], best_classifiers[i]

# Logo, o melhor classifiers será:

best_model = best_classifiers[-1][2]
C = best_classifiers[-1][0]
gamma = best_classifiers[-1][1]
X_train = best_train_test[0]
X_test = best_train_test[1]
Y_train = best_train_test[2]
Y_test = best_train_test[3]
```

In [ ]:

```
# Assim conseguimos achar o melhor modelo dentre 100 testados, o que ainda não é o melhor. Com isso, vamos plotar os resultados para ter uma visualização gráfica:

plt.figure(figsize=(15, 10))
plt.scatter(range(len(Y_test)), Y_test, label="Y_test", color="k")
plt.scatter(range(len(Y_test)), best_model.predict(X_test), label="Y_pred", marker='x', color="r")
plt.legend()
plt.grid()
plt.savefig("test")
```

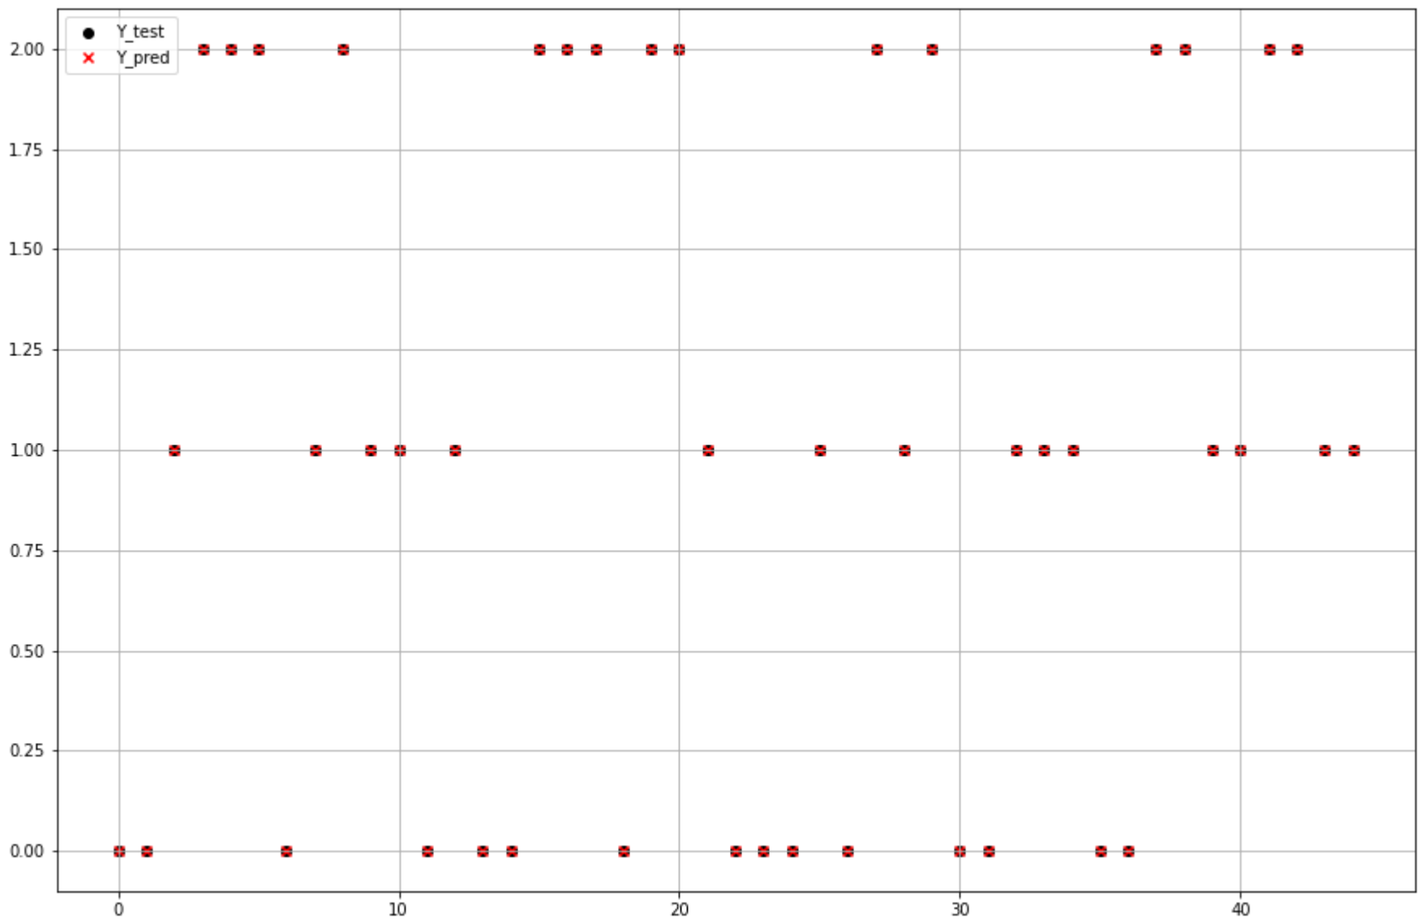

In [ ]:

```
# O modelo de regressão será:

from sklearn.svm import SVR

svr = SVR(kernel="rbf", C=C, gamma=gamma)
svr.fit(X_train, Y_train)

plt.figure(figsize=(15, 10))
plt.plot(range(len(Y_test)), Y_test, label="Y_test", color="k")
plt.plot(range(len(Y_test)), svr.predict(X_test), label="Y_pred", marker='x', color="r")
plt.legend()
plt.grid()
plt.savefig("testR")
```

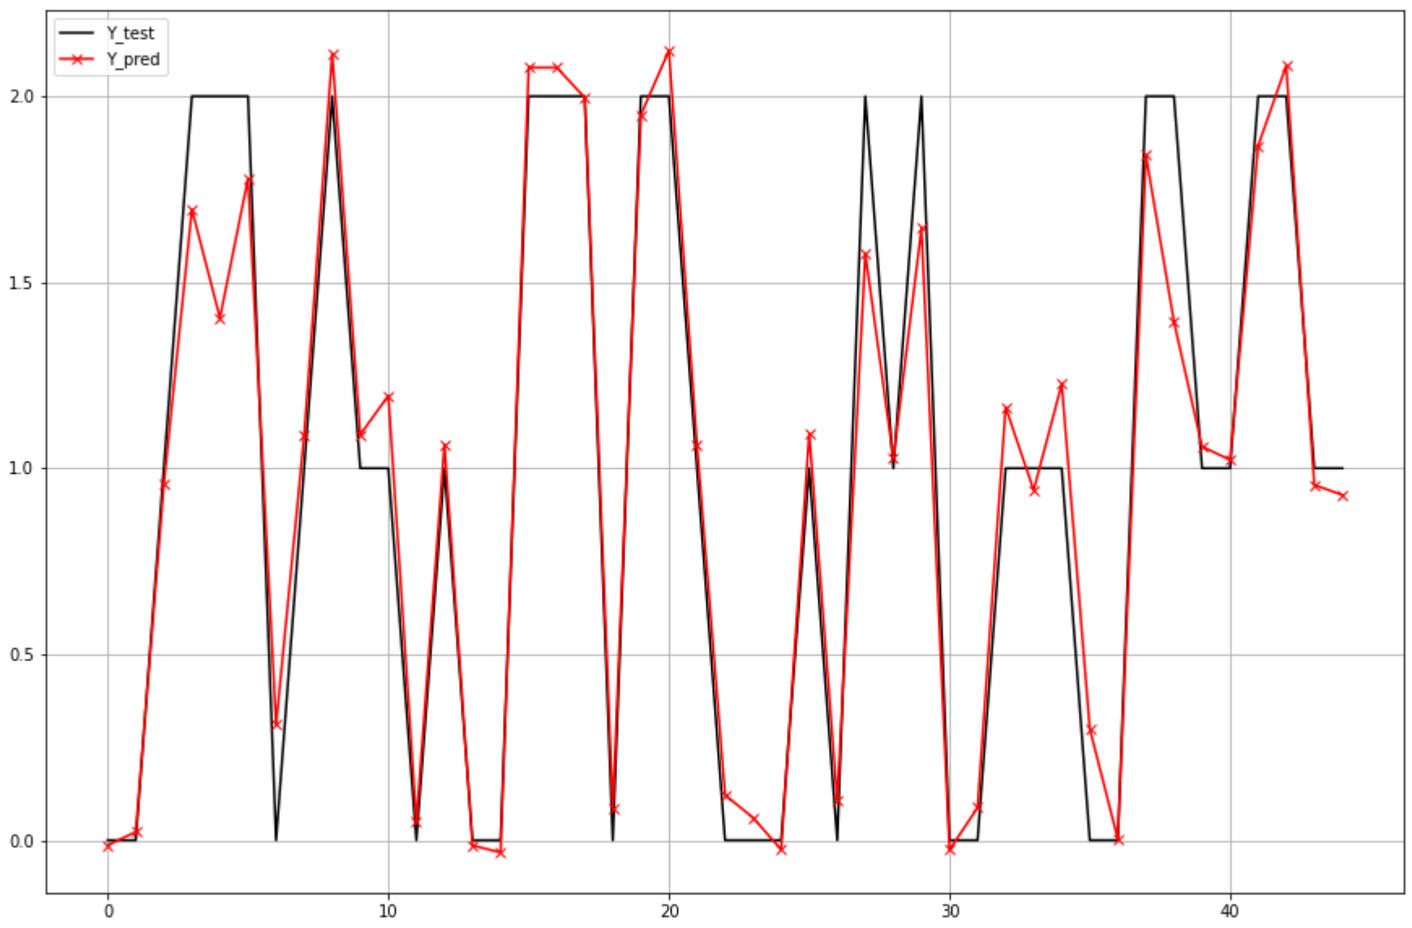

In [ ]:

```
# Ainda assim, podemos modificar tudo feito para achar um modelo com um valor mímino para a accuracy:

import numpy as np
import matplotlib.pyplot as plt
from sklearn.svm import SVC
from sklearn.model_selection import train_test_split
from sklearn import metrics

accuracy_media = 0

while accuracy_media <= 0.9:

    accuracy_media = 0

    # Dividimos o conjunto de dados, sendo 30% para teste e 70% para treinamento:

    X_train, X_test, Y_train, Y_test = train_test_split(X, Y, test_size=0.3)

    # Iremos definar 3 valores para gamma e 3 valores para C, cruzando todos os possíveis parâmetros e montando um total de 9 classificadores diferentes:

    C_ = [1e-2, 1, 1e2]
    gamma_ = [1e-1, 1, 1e1]
    classifiers = []

    # Para cada modelo, guardaremos o valor de C, gamma, clf e a accuracy

    for C in C_:
        for gamma in gamma_:
            clf = SVC(C=C, gamma=gamma)
            clf.fit(X_train, Y_train)
            Y_pred = clf.predict(X_test)
            accuracy = metrics.accuracy_score(Y_test, Y_pred)
            accuracy_media += accuracy
            classifiers.append((C, gamma, clf, accuracy))
```

```
    accuracy_media = accuracy_media/9

print(f'A accuaracy obtido foi de: {accuracy_media}')


# Assim, iremos ordenar o modelo best para achar os melhores valores para C e gamma

for i in range(len(classifiers)):
    for j in range(i + 1, len(classifiers)):
        if classifiers[i][3] > classifiers[j][3]:
            classifiers[i], classifiers[j] = classifiers[j], classifiers[i]

# Logo, o melhor classifiers será:

best_model = classifiers[-1][2]
C = classifiers[-1][0]
gamma = classifiers[-1][1]

plt.figure(figsize=(15, 10))
plt.scatter(range(len(Y_test)), Y_test, label="Y_test", color="k")
plt.scatter(range(len(Y_test)), best_model.predict(X_test), label="Y_pred", marker='x', color="r")
plt.legend()
plt.grid()

from sklearn.svm import SVR

svr = SVR(kernel="rbf", C=C, gamma=gamma)
svr.fit(X_train, Y_train)

plt.figure(figsize=(15, 10))
plt.plot(range(len(Y_test)), Y_test, label="Y_test", color="k")
plt.plot(range(len(Y_test)), svr.predict(X_test), label="Y_pred", marker='x', color="r")
plt.legend()
plt.grid()
```

```
A accuaracy obtido foi de: 0.9308641975308642
```